



GEM
Beps Smart Research

— • CURSO PRÁCTICO INTENSIVO • —

R Y RSTUDIO PARA EL ANÁLISIS DE DATOS

Fundamentos para Econometría



Manual práctico del estudiante



10 horas



5 sesiones de 2 horas



— Docente —

Mg. Miguel Jesús Armando Paredes Trujillo

Maestro en Ciencias Económicas y Economía Aplicada

Econometrista | Científico de Datos | Investigador Senior



Beps Smart Research

Material académico para uso formativo

Contenido

Resultado del curso.....	3
Ruta de 10 horas.....	3
Diccionario de la base de empleo.....	4
1. R y RStudio: dos cosas diferentes.....	6
2. Tu primer script.....	6
3. Operaciones y funciones.....	6
4. Tipos de datos.....	7
5. Vectores: una columna de datos.....	7
6. NA: dato faltante.....	8
7. Data frame: la estructura central.....	8
8. Selección de filas y columnas.....	8
9. Matrices: puente conceptual.....	8
1. Proyectos y rutas relativas.....	10
2. Paquetes.....	10
3. Importar CSV, Excel y Stata.....	10
4. Auditoría rápida de una base.....	11
5. Duplicados e identificadores.....	11
6. Texto inconsistente.....	11
7. Verbos fundamentales de dplyr.....	12
8. Limpieza reproducible.....	12
9. Crear variables.....	12
1. Estadísticos descriptivos esenciales.....	15
2. Frecuencias.....	15
3. group_by() + summarise().....	15
4. Llaves y joins.....	16
5. Visualización con ggplot2.....	16
6. Correlación.....	17
1. Logaritmos.....	18
2. Variables dummy.....	18
3. Términos cuadráticos.....	18
4. Factores y categoría de referencia.....	18
5. Interacciones: una primera lectura.....	19
6. ¿Qué es un panel?.....	19
7. Rezagos y diferencias.....	19
8. Fórmulas de modelo en R.....	20
1. Pipeline completo.....	21
2. Regresión lineal simple.....	21
3. Regresión múltiple.....	22
4. Objetos que devuelve un modelo.....	22
5. Predicción didáctica.....	22
6. Diagnóstico visual introductorio.....	22
7. Exportar resultados.....	23

Cómo usar este manual

Este manual está diseñado para trabajar directamente en RStudio. Lee una explicación breve, ejecuta el código, observa qué cambia y resuelve la casuística. El objetivo no es memorizar comandos: es construir un flujo ordenado, reproducible y preparado para análisis econométrico.

Regla de trabajo

Carpeta raíz → RStudio Project → R Script (.R) → paquetes → importación → auditoría/limpieza → análisis → exportación. Usa la consola solo para pruebas rápidas y conserva siempre las bases brutas sin modificar.

Resultado del curso

- Crear y organizar una carpeta raíz y un RStudio Project con datos, scripts, resultados y gráficos separados.
- Distinguir Consola, R Script (.R), R Markdown (.Rmd) y Markdown (.md), y reconocer cuándo usar cada uno.
- Importar bases CSV, Excel y Stata; inspeccionar su estructura antes de analizarlas.
- Limpiar y transformar datos con dplyr.
- Construir tablas descriptivas, unir bases y visualizar relaciones con ggplot2.
- Crear variables habituales en econometría: logaritmos, dummies, términos cuadráticos, rezagos y diferencias.
- Preparar una base reproducible y ejecutar una primera regresión lineal con lm().

Ruta de 10 horas

Sesión	Núcleo práctico	Producto
1	Entorno, organización, R Script, objetos, data frames y NA	Proyecto ordenado + primer script
2	Importación, inspección, limpieza y transformación	Base depurada para análisis
3	Resúmenes, joins y visualización	Tabla regional y gráficos
4	Variables econométricas y estructura de panel	Base lista para modelamiento
5	Pipeline reproducible y lm()	Mini proyecto integrado

Archivos de práctica

Importante

Las bases entregadas con el curso son simuladas con fines pedagógicos. No deben interpretarse como estadísticas oficiales del Perú.

Archivo	Contenido	Uso principal
empleo_peru_bruto.csv / .xlsx / .dta	Registros individuales de empleo con errores intencionales	Importación, limpieza, descriptivos y regresión
contexto_regional_2025.csv	Pobreza, inflación e inversión pública por región	Joins y análisis regional
panel_regional_2022_2025.csv	Región-año, 2022-2025	Rezagos, diferencias y estructura panel
practica_vectores.csv	Serie corta de ingresos	Ejercicios iniciales

Diccionario de la base de empleo

Variable	Tipo	Significado
id_persona	entero	Identificador individual
region	carácter	Región de residencia
sexo	carácter	Mujer/Hombre
edad	numérico	Edad en años
educacion_anios	numérico	Años de educación
experiencia_anios	numérico	Años aproximados de experiencia
ingreso_mensual	numérico	Ingreso laboral mensual simulado
formal	carácter	Si/No
sector	carácter	Actividad económica

ANTES DE INICIAR · ORGANIZA TU ENTORNO DE TRABAJO

Crea una carpeta raíz por proyecto. Así puedes mover el trabajo completo, mantener las bases originales intactas y separar claramente código, datos procesados y resultados.

```
Curso_R_GEM/
├─ Curso_R_GEM.Rproj
├─ 01_datos_brutos/    # originales
├─ 02_datos_procesados/ # bases limpias
├─ 03_scripts/         # archivos .R
├─ 04_resultados/      # tablas/salidas
├─ 05_graficos/        # figuras

getwd()
# setwd("D:/Curso_R_GEM") # solo si no usas .Rproj
```


R Script, R Markdown y Markdown

Formato	Uso principal	Recomendación
R Script (.R)	Código, limpieza, transformación, modelamiento	Principal para el curso y para flujos locales: ligero, modular y escalable.
R Markdown (.Rmd)	Texto + código + resultados	Úsalo cuando debas entregar un informe reproducible con narrativa y salidas.
Markdown (.md)	Texto con formato simple	Útil para documentación; no ejecuta código R por sí solo.

Paquetes: `install.packages()` instala una vez; `library()` carga en cada sesión. También puedes usar Tools > Install Packages. Recomendación: instala solo lo necesario y deja las líneas de instalación comentadas en el script.

Recomendación de trabajo

Para análisis locales y proyectos de datos, usa R Script (.R) como archivo principal: es ligero, modular, fácil de versionar y permite separar limpieza, análisis y resultados. Usa R Markdown (.Rmd) cuando necesites entregar un informe reproducible que combine narrativa, código y salidas. Para instalar paquetes puedes usar `install.packages()` o Tools > Install Packages; deja la instalación comentada y carga los paquetes con `library()` al inicio.

SESIÓN 1 · Pensar en R

RStudio, objetos, vectores, data frames y valores faltantes

Idea central

R trabaja con objetos. Un objeto puede contener un número, texto, una condición lógica, un vector, una tabla o un modelo. La asignación `<-` permite guardar un resultado para usarlo después.

1. R y RStudio: dos cosas diferentes

R es el lenguaje y motor de computación estadística. RStudio es el entorno de desarrollo donde escribirás, guardarás y ejecutarás el código. En este curso la consola se reserva para pruebas rápidas; el trabajo principal se conserva en R Scripts (.R) dentro de la carpeta 03_scripts/.

Zona de RStudio	Uso
Source / Script	Escribir y guardar código .R; trabajo principal del curso
Console	Probar instrucciones y revisar resultados inmediatos
Environment	Observar objetos creados en memoria
Files / Plots / Packages / Help	Administrar archivos, gráficos, paquetes y documentación

2. Tu primer script

```
# 03_scripts/01_fundamentos.R
# Ctrl + Enter ejecuta la línea o selección
2 + 3
x <- 10
y <- 25
x + y
```

Buena práctica

Crea el archivo desde File > New File > R Script y guárdalo antes de avanzar. Un análisis que solo vive en la consola no es reproducible.

3. Operaciones y funciones

```
5 + 2
10 - 3
6 * 12
100 / 4
2^3
sqrt(81)
log(100)
```

Símbolo / función	Lectura
+	suma
-	resta
*	multiplicación
/	división
^	potencia
sqrt()	raíz cuadrada
log()	logaritmo natural

4. Tipos de datos

```
edad <- 35
region <- "Lima"
formal <- TRUE
```

```
class(edad)
class(region)
class(formal)
```

Clave

Las comillas indican texto. TRUE y FALSE son valores lógicos. Entender el tipo de una variable evita errores al sumar, comparar, agrupar o modelar.

5. Vectores: una columna de datos

```
ingreso <- c(1250, 1800, 2300, 950, 3200, 2700, 1600, 4100, NA)
edad <- c(22, 28, 35, 41, 30, 50, 26, 38, 31)
```

```
length(ingreso)
ingreso[1]
ingreso[2:5]
ingreso[c(1, 3, 8)]
```

Los corchetes `[]` permiten seleccionar posiciones. Si dentro de los corchetes colocas una condición lógica, R conserva las posiciones donde la condición es TRUE.

```
ingreso[ingreso > 2000]
edad[ingreso > 2000]
```

6. NA: dato faltante

```
is.na(ingreso)
sum(is.na(ingreso))
mean(ingreso)
mean(ingreso, na.rm = TRUE)
```

Error frecuente

NA no se busca con `ingreso == NA`. Utiliza `is.na(ingreso)`. Cuando una función tiene el argumento `na.rm = TRUE`, los valores faltantes se excluyen del cálculo.

7. Data frame: la estructura central

```
trabajadores <- data.frame(
  id = 1:8,
  sexo = c("Mujer", "Hombre", "Hombre", "Mujer", "Mujer", "Hombre", "Mujer", "Hombre"),
  edad = c(22, 28, 35, 41, 30, 50, 26, 38),
  educacion = c(12, 16, 14, 11, 18, 12, 16, 14),
  ingreso = c(1250, 1800, 2300, 950, 3200, 2700, 1600, 4100)
)

head(trabajadores)
dim(trabajadores)
names(trabajadores)
str(trabajadores)
summary(trabajadores)
```

Lectura

En una base rectangular, las filas suelen representar observaciones y las columnas variables. Antes de calcular cualquier estadístico, comprueba cuántas filas hay, qué variables existen y de qué tipo son.

8. Selección de filas y columnas

```
trabajadores$ingreso
trabajadores[["ingreso"]]
trabajadores[1, ]
trabajadores[1:3, ]
trabajadores[trabajadores$ingreso > 2000, ]
```

9. Matrices: puente conceptual

No necesitas dominar álgebra matricial en este curso, pero sí reconocer que muchos procedimientos econométricos se expresan mediante matrices. En R, `%*%` realiza multiplicación matricial y `t()` transpone una matriz.

```
X <- matrix(c(1,1,1,2,4,6), nrow = 3, ncol = 2)
```



```
y <- matrix(c(10,20,30), ncol = 1)
X
t(X)
t(X) %*% X
```

EJERCICIO 1.1. Ingresos y filtros

Caso. Una unidad de análisis laboral dispone de nueve ingresos mensuales; uno está perdido. Antes de continuar con el estudio debes describir la serie y localizar los valores altos.

Resuelve en R:

1. Crea el vector ingreso con los valores mostrados en la sección 5.
2. Calcula número de observaciones, cantidad de NA, media, mediana y máximo.
3. Obtén solamente los ingresos mayores a 2 000.
4. Cuenta cuántas observaciones superan 2 000.
5. Explica en una frase por qué `mean(ingreso)` devuelve NA y cómo corregirlo.

EJERCICIO 1.2. Primera base laboral

Caso. Construye el data frame trabajadores mostrado en el manual y úsalo como una pequeña base de corte transversal.

Resuelve en R:

6. Identifica el número de filas y columnas.
7. Extrae la columna ingreso de tres formas distintas.
8. Obtén todos los trabajadores con ingreso mayor a 2 000.
9. Calcula el ingreso promedio de las mujeres.
10. Identifica la persona con mayor ingreso.

Reto

Sin usar Excel, agrega una nueva columna `ingreso_anual = ingreso * 12`.

SESIÓN 2 · De archivo bruto a base analítica

Importación, inspección, limpieza y transformación

Idea central

Un modelo no corrige una base mal construida. Antes de analizar, debes saber qué importaste, detectar errores y documentar las transformaciones.

1. Proyectos y rutas relativas

Trabaja dentro de la carpeta raíz del proyecto. La práctica recomendada es crear primero la carpeta y luego asociarla con File > New Project > Existing Directory. Al abrir el archivo .Rproj, RStudio toma esa carpeta como referencia y puedes usar rutas relativas. `setwd()` sirve para direccionar el working directory, pero evita dejar rutas personales fijas cuando el script será compartido.

```
getwd()
# setwd("D:/Curso_R_GEM") # si no abriste el .Rproj
list.files()
list.files("01_datos_brutos")
```

2. Paquetes

Un paquete amplía las funciones de R. `install.packages()` instala el paquete en la computadora y normalmente se ejecuta una sola vez; `library()` lo carga en la sesión actual. También puedes instalarlo manualmente en RStudio desde Tools > Install Packages. Mantén las líneas de instalación comentadas en el script para no reinstalar en cada clase.

```
# INSTALAR: una sola vez si hace falta
# install.packages("tidyverse")
# install.packages(c("tidyverse", "readxl", "haven"))

# CARGAR: en cada nueva sesión
library(tidyverse)
library(readxl)
library(haven)

# Alternativa: paquete::función
# dplyr::select(base, variable1, variable2)
```

3. Importar CSV, Excel y Stata

```
empleo <- read_csv("01_datos_brutos/empleo_peru_bruto.csv")
empleo_xlsx <- read_excel("01_datos_brutos/empleo_peru_bruto.xlsx")
empleo_dta <- read_dta("01_datos_brutos/empleo_peru_bruto.dta")
# Opcional: empleo_sav <- read_sav("01_datos_brutos/empleo_peru_bruto.sav")
```

Buena práctica

Después de importar, no empieces a modelar. Primero inspecciona dimensiones, nombres, tipos, valores faltantes y categorías.

4. Auditoría rápida de una base

```
head(empleo)
tail(empleo)
dim(empleo)
glimpse(empleo)
names(empleo)
summary(empleo)
colSums(is.na(empleo))
```

Pregunta	Comando útil
¿Cuántas observaciones y variables hay?	dim()
¿Cómo se llaman las variables?	names()
¿Qué tipo tiene cada columna?	glimpse() / str()
¿Qué rangos y faltantes aparecen?	summary()
¿Cuántos NA tiene cada variable?	colSums(is.na())

5. Duplicados e identificadores

Un identificador debe ser único cuando cada fila representa una persona. Si un id aparece más de una vez, primero debes determinar si es un duplicado real o si la unidad de análisis admite varias filas por persona.

```
empleo |>
  count(id_persona) |>
  filter(n > 1)
```

6. Texto inconsistente

```
sort(unique(empleo$region))
```

“Lima”, “lima” y “Lima ” pueden representar la misma región pero no son cadenas idénticas. Antes de unir bases, estandariza el texto.

```
empleo <- empleo |>
  mutate(region = str_to_title(str_trim(region)))
```

7. Verbos fundamentales de dplyr

Verbo	Función mental	Ejemplo
<code>select()</code>	quedarte con columnas	<code>select(region, sexo, ingreso_mensual)</code>
<code>filter()</code>	quedarte con filas	<code>filter(region == "Lima")</code>
<code>arrange()</code>	ordenar	<code>arrange(desc(ingreso_mensual))</code>
<code>rename()</code>	renombrar columnas	<code>rename(ingreso = ingreso_mensual)</code>
<code>mutate()</code>	crear o transformar variables	<code>mutate(ln_ingreso = log(ingreso_mensual))</code>
<code>distinct()</code>	eliminar duplicados	<code>distinct(id_persona, .keep_all = TRUE)</code>

8. Limpieza reproducible

```
empleo_limpio <- empleo |>
  distinct(id_persona, .keep_all = TRUE) |>
  mutate(
    region = str_to_title(str_trim(region)),
    edad = if_else(edad >= 18 & edad <= 80, edad, NA_real_),
    ingreso_mensual = if_else(ingreso_mensual > 0, ingreso_mensual, NA_real_)
  )
```

¿Por qué convertir errores a NA?

Porque un valor imposible como edad = 130 o ingreso = -150 no debe entrar a un promedio o modelo como si fuera información válida. Convertirlo a NA hace explícito que falta un valor utilizable. La decisión final de eliminar, imputar o recuperar ese dato depende del diseño del estudio.

9. Crear variables

```
empleo_limpio <- empleo_limpio |>
  mutate(
    ingreso_anual = ingreso_mensual * 12,
    ln_ingreso = log(ingreso_mensual),
    mujer = if_else(sexo == "Mujer", 1, 0),
    formal_dummy = if_else(formal == "Si", 1, 0)
  )
```

EJERCICIO 2.1. Auditoría de la base bruta

Archivo de trabajo

01_datos_brutos/empleo_peru_bruto.csv

Caso. Recibiste empleo_peru_bruto.csv y debes entregarlo limpio antes de cualquier análisis.

Resuelve en R:

11. Importa el archivo y registra sus dimensiones.
12. Cuenta los NA por columna.
13. Busca identificadores duplicados.
14. Lista las categorías únicas de region y detecta inconsistencias.
15. Identifica edades fuera del rango 18-80 e ingresos menores o iguales a 0.
16. Crea empleo_limpio corrigiendo duplicados, región, edad e ingreso.
17. Comprueba que el número de duplicados sea cero después de la limpieza.

EJERCICIO 2.2. Base para un modelo de ingreso

Caso. A partir de empleo_limpio, prepara una base con solo las variables necesarias para estudiar ingreso laboral.

Resuelve en R:

18. Conserva id, región, sexo, edad, educación, experiencia, ingreso, formalidad y sector.
19. Elimina del análisis las filas sin ingreso, edad o educación válidos.
20. Crea ln_ingreso, experiencia2, mujer y formal_dummy.
21. Ordena la base de mayor a menor ingreso.
22. Muestra únicamente los cinco mayores ingresos con id, región y sexo.

CASUÍSTICA 2.3 · Proyecto reproducible en otra computadora

Caso. Recibes el proyecto de otro analista. Su script contiene `setwd("C:/Users/Analista/Desktop/Curso_R_GEM")` y deja de funcionar en tu equipo. Debes corregir el flujo sin modificar manualmente las bases.

1. Abre `Curso_R_GEM.Rproj` y verifica `getwd()`.
2. Comprueba con `list.files()` que exista `01_datos_brutos`.
3. Sustituye la ruta personal por una ruta relativa.
4. Si falta `tidyverse`, instálalo por código o desde `Tools > Install Packages`; luego usa `library(tidyverse)`.
5. Importa, audita y guarda cualquier base derivada en `02_datos_procesados`.
6. Exporta resultados a `04_resultados` y gráficos a `05_graficos`.

Criterio: si copias la carpeta completa a otra ubicación, el script debe seguir funcionando sin editar rutas personales.

Reto

Escribe todo el proceso anterior en una sola cadena con el pipe `|>`.

SESIÓN 3 · Convertir datos en información

Estadística descriptiva, agrupación, joins y visualización

Idea central

La exploración descriptiva ayuda a entender distribución, magnitud, heterogeneidad y posibles relaciones. Un gráfico o una correlación describen asociación; no prueban causalidad.

1. Estadísticos descriptivos esenciales

```
mean(empleo_limpio$ingreso_mensual, na.rm = TRUE)
median(empleo_limpio$ingreso_mensual, na.rm = TRUE)
sd(empleo_limpio$ingreso_mensual, na.rm = TRUE)
quantile(empleo_limpio$ingreso_mensual, c(.25, .5, .75), na.rm = TRUE)
```

Estadístico	Pregunta que responde
Media	¿Cuál es el promedio?
Mediana	¿Cuál es el valor central resistente a extremos?
Desviación estándar	¿Cuánto se dispersan los valores?
Cuartiles	¿Cómo se distribuye la variable por posiciones?

2. Frecuencias

```
table(empleo_limpio$sexo)
prop.table(table(empleo_limpio$sexo))
```

3. group_by() + summarise()

```
resumen_region <- empleo_limpio |>
  group_by(region) |>
  summarise(
    n = n(),
    ingreso_promedio = mean(ingreso_mensual, na.rm = TRUE),
    ingreso_mediano = median(ingreso_mensual, na.rm = TRUE),
    educacion_promedio = mean(educacion_anios, na.rm = TRUE),
    formalidad_pct = mean(formal == "Si") * 100,
    .groups = "drop"
  ) |>
  arrange(desc(ingreso_promedio))
```

La lógica es sencilla: primero defines los grupos; después reduces cada grupo a uno o varios indicadores.

4. Llaves y joins

Para agregar información regional a una tabla de personas o a un resumen regional necesitas una llave compatible. Si la llave es region, los valores deben coincidir exactamente en ambas bases.

```
contexto <- read_csv("01_datos_brutos/contexto_regional_2025.csv")

base_regional <- resumen_region |>
  left_join(contexto, by = "region")
```

Join	Qué conserva
<code>left_join(x, y)</code>	Todas las filas de x; agrega coincidencias de y
<code>inner_join(x, y)</code>	Solo las filas con coincidencia en x e y
<code>full_join(x, y)</code>	Todas las filas de ambas bases
<code>anti_join(x, y)</code>	Filas de x sin coincidencia en y

```
# Diagnóstico de regiones que no encontraron pareja
resumen_region |>
  anti_join(contexto, by = "region")
```

5. Visualización con ggplot2

La gramática de ggplot2 se construye por capas: datos + estética (aes) + geometría (geom).

Histograma

```
ggplot(empleo_limpio, aes(x = ingreso_mensual)) +
  geom_histogram(bins = 15) +
  labs(title = "Distribución del ingreso mensual",
       x = "Ingreso mensual", y = "Frecuencia")
```

Boxplot

```
ggplot(empleo_limpio, aes(x = formal, y = ingreso_mensual)) +
  geom_boxplot() +
  labs(title = "Ingreso según formalidad",
       x = "Formalidad", y = "Ingreso mensual")
```

Dispersión con tendencia lineal

```
ggplot(empleo_limpio, aes(x = educacion_anios, y = ingreso_mensual)) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE) +
  labs(title = "Educación e ingreso",
       x = "Años de educación", y = "Ingreso mensual")
```

Interpretación responsable

Si la nube de puntos sugiere una pendiente positiva, puedes decir que existe una asociación visual positiva en la muestra. No puedes concluir que aumentar educación causa automáticamente un aumento de ingreso sin un diseño e identificación causal adecuados.

6. Correlación

```
cor(empleo_limpio$educacion_anios,  
    empleo_limpio$ingreso_mensual,  
    use = "complete.obs")
```

La correlación resume intensidad y dirección de una relación lineal entre dos variables numéricas. No sustituye el análisis gráfico ni controla otras variables.

EJERCICIO 3.1. Perfil laboral por grupos

Archivo de trabajo

01_datos_brutos/empleo_peru_bruto.csv

Caso. La gerencia quiere comparar ingresos y educación por sexo y formalidad.

Resuelve en R:

23. Agrupa por sexo y formalidad.
24. Calcula n, ingreso promedio y educación promedio.
25. Ordena los grupos de mayor a menor ingreso.
26. Escribe dos conclusiones descriptivas sin utilizar lenguaje causal.

EJERCICIO 3.2. Contexto regional

Archivo de trabajo

01_datos_brutos/contexto_regional_2025.csv

Caso. Debes incorporar pobreza, inflación e inversión pública 2025 al resumen laboral por región.

Resuelve en R:

27. Importa contexto_regional_2025.csv.
28. Verifica que region sea única en la base regional.
29. Une resumen_region con contexto usando left_join().
30. Comprueba con anti_join() si alguna región quedó sin pareja.
31. Grafica pobreza_pct frente a ingreso_promedio.
32. Describe la dirección de la relación observada.

Reto

¿Qué problema ocurriría si una misma región apareciera dos veces en la base contexto con el mismo año?

SESIÓN 4 · Preparar variables para econometría

Logaritmos, dummies, términos cuadráticos, factores, rezagos y panel

Idea central

La calidad del modelo depende también de cómo defines las variables. La transformación debe responder a una razón analítica, no a “probar hasta que salga significativo”.

1. Logaritmos

El logaritmo natural es habitual cuando una variable positiva presenta gran dispersión o cuando interesa interpretar relaciones en términos proporcionales. Nunca apliques `log()` a valores cero o negativos sin revisar su significado.

```
base <- empleo_limpio | >
mutate(ln_ingreso = log(ingreso_mensual))
```

2. Variables dummy

Una dummy representa una condición con 1 y 0. El significado depende de qué categoría recibe el valor 1.

```
base <- base | >
mutate(
  mujer = if_else(sexo == "Mujer", 1, 0),
  formal_dummy = if_else(formal == "Si", 1, 0)
)
```

3. Términos cuadráticos

Un término cuadrático permite que la pendiente cambie con el nivel de una variable. Es frecuente, por ejemplo, cuando se espera que el retorno de la experiencia disminuya a medida que la experiencia aumenta.

```
base <- base | >
mutate(experiencia2 = experiencia_anios^2)
```

4. Factores y categoría de referencia

```
base <- base | >
mutate(
  sexo = factor(sexo),
  formal = factor(formal),
  sector = factor(sector)
)

levels(base$sexo)
base$sexo <- relevel(base$sexo, ref = "Hombre")
```

Clave

En modelos con variables categóricas, la interpretación de los coeficientes se hace respecto de una categoría de referencia.

5. Interacciones: una primera lectura

Una interacción permite que la asociación de una variable con Y sea diferente según el nivel de otra. En este curso basta reconocer la sintaxis.

```
# En una fórmula de modelo
y ~ educacion_anios * formal

# Equivale a incluir:
# educacion_anios + formal + educacion_anios:formal
```

6. ¿Qué es un panel?

Un panel observa varias unidades a lo largo de varios periodos. En `panel_regional_2022_2025.csv` la unidad es la región y el tiempo es el año. La pareja `region + anio` debe identificar una fila única.

```
panel <- read_csv("01_datos_brutos/panel_regional_2022_2025.csv")

panel |> count(region, anio) |> filter(n > 1)
n_distinct(panel$region)
n_distinct(panel$anio)
nrow(panel)
```

Chequeo rápido

Si existen 10 regiones observadas durante 4 años y el panel está completo, deberías tener 40 filas.

7. Rezagos y diferencias

```
panel <- panel |>
  arrange(region, anio) |>
  group_by(region) |>
  mutate(
    inversion_lag1 = lag(inversion_publica_pc, 1),
    delta_ingreso = ingreso_pc - lag(ingreso_pc, 1),
    crecimiento_ingreso_pct = (ingreso_pc / lag(ingreso_pc, 1) - 1) * 100
  ) |>
  ungroup()
```

Muy importante

Antes de usar `lag()`, ordena por unidad y tiempo y agrupa por la unidad. De lo contrario, el “rezago” puede tomar el valor de otra región.

8. Fórmulas de modelo en R

Sintaxis	Lectura
$y \sim x$	y explicada por x
$y \sim x1 + x2$	y explicada por x1 y x2
$\log(y) \sim x$	modelo con logaritmo de y
$y \sim x + I(x^2)$	incluye x y x al cuadrado
$y \sim x1 * x2$	efectos principales + interacción

EJERCICIO 4.1. Base econométrica de ingreso

Caso. Prepara una base individual que pueda utilizarse en una regresión introductoria.

Resuelve en R:

33. Filtra observaciones con ingreso, educación y experiencia válidos.
34. Crea `ln_ingreso`, `experiencia2`, `mujer` y `formal_dummy`.
35. Convierte sexo, formal y sector en factor.
36. Define Hombre como referencia de sexo y No como referencia de formalidad.
37. Explica qué significa que `mujer = 1`.

EJERCICIO 4.2. Panel regional

Archivo de trabajo

01_datos_brutos/panel_regional_2022_2025.csv

Caso. Trabaja con `panel_regional_2022_2025.csv`.

Resuelve en R:

38. Comprueba que `region + anio` sea único.
39. Confirma número de regiones, años y filas.
40. Crea el rezago de inversión pública dentro de cada región.
41. Crea la variación anual del ingreso per cápita.
42. Muestra únicamente la trayectoria de Lima.
43. Calcula pobreza, ingreso e inversión promedio por año.

Reto

Borra temporalmente `arrange(region, anio)` y observa por qué el orden es parte del significado de un rezago.

SESIÓN 5 · Del dato bruto a una primera regresión

Pipeline reproducible, lm(), interpretación inicial y exportación

Idea central

La regresión es el final del flujo, no el inicio. Un análisis reproducible permite volver al archivo bruto, ejecutar el script desde arriba y reconstruir la base y los resultados.

1. Pipeline completo

```
base_final <- read_csv("01_datos_brutos/empleo_peru_bruto.csv") |>
  distinct(id_persona, .keep_all = TRUE) |>
  mutate(
    region = str_to_title(str_trim(region)),
    edad = if_else(edad >= 18 & edad <= 80, edad, NA_real_),
    ingreso_mensual = if_else(ingreso_mensual > 0, ingreso_mensual, NA_real_)
  ) |>
  filter(
    !is.na(ingreso_mensual),
    !is.na(educacion_anios),
    !is.na(experiencia_anios)
  ) |>
  mutate(
    ln_ingreso = log(ingreso_mensual),
    experiencia2 = experiencia_anios^2,
    sexo = factor(sexo),
    formal = factor(formal)
  )
```

2. Regresión lineal simple

La sintaxis básica de lm() es lm(y ~ x, data = base).

```
m1 <- lm(ingreso_mensual ~ educacion_anios, data = base_final)
summary(m1)
coef(m1)
```

Elemento	Lectura
ingreso_mensual	variable dependiente Y
educacion_anios	variable explicativa X
(Intercept)	valor estimado de Y cuando X = 0, si esa interpretación tiene sentido
coeficiente de educación	cambio estimado en Y asociado con una unidad adicional de educación en este modelo

Límite metodológico

Un coeficiente de regresión describe una relación condicional bajo el modelo. Por sí solo no demuestra un efecto causal. La causalidad exige supuestos y diseño de identificación que se estudian en econometría.

3. Regresión múltiple

```
base_final$sexo <- relevel(base_final$sexo, ref = "Hombre")
base_final$formal <- relevel(base_final$formal, ref = "No")

m2 <- lm(
  ln_ingreso ~ educacion_anios + experiencia_anios +
    experiencia2 + sexo + formal,
  data = base_final
)

summary(m2)
```

4. Objetos que devuelve un modelo

```
coef(m2)
fitted(m2) |> head()
residuals(m2) |> head()
nobs(m2)
```

Residuo

Para una observación, el residuo es la diferencia entre el valor observado y el valor ajustado por el modelo. Los residuos son fundamentales para diagnosticar si los supuestos del modelo parecen razonables.

5. Predicción didáctica

```
nuevo <- data.frame(
  educacion_anios = 16,
  experiencia_anios = 8,
  experiencia2 = 8^2,
  sexo = factor("Hombre", levels = levels(base_final$sexo)),
  formal = factor("Si", levels = levels(base_final$formal))
)

predict(m2, newdata = nuevo)
exp(predict(m2, newdata = nuevo))
```

6. Diagnóstico visual introductorio

```
par(mfrow = c(2, 2))
```



```
plot(m2)
par(mfrow = c(1, 1))
```

En un curso posterior de econometría aprenderás a interpretar formalmente heterocedasticidad, normalidad de residuos, observaciones influyentes y otras pruebas. Aquí debes reconocer que estimar un modelo es solo una parte del proceso.

7. Exportar resultados

```
if (!dir.exists("04_resultados")) dir.create("04_resultados")
if (!dir.exists("05_graficos")) dir.create("05_graficos")

write_csv(base_final, "04_resultados/base_final.csv")
coeficientes <- tibble(termino = names(coef(m2)), estimacion = unname(coef(m2)))
write_csv(coeficientes, "04_resultados/coeficientes_m2.csv")
```

EJERCICIO 5.1. Mini proyecto final: determinantes asociados al ingreso laboral

Archivo de trabajo

01_datos_brutos/empleo_peru_bruto.csv

Caso. Una unidad de investigación necesita una primera exploración reproducible de la relación entre ingreso, educación, experiencia, sexo y formalidad en una base simulada.

Resuelve en R:

44. Importa empleo_peru_bruto.csv y reconstruye base_final desde cero.
45. Documenta y corrige duplicados, categorías regionales, edades imposibles e ingresos no válidos.
46. Obtén n, ingreso medio, ingreso mediano, educación media y experiencia media.
47. Compara ingreso promedio por formalidad.
48. Grafica educación frente a ln_ingreso e incorpora una tendencia lineal.
49. Estima m1: ingreso_mensual ~ educacion_anios.
50. Estima m2: ln_ingreso ~ educacion_anios + experiencia_anios + experiencia2 + sexo + formal.
51. Identifica el signo de cada coeficiente y redacta una interpretación descriptiva prudente.
52. Indica cuántas observaciones utilizó m2.
53. Exporta la base final y una tabla de coeficientes a la carpeta resultados.

Reto

Redacta tres conclusiones del mini proyecto. En ninguna uses las palabras “causa”, “impacta” o “efecto” salvo que expliques por qué el diseño del ejercicio no permite afirmarlo.

Hoja rápida de comandos

Tarea	Código
Asignar	<code>x <- 10</code>
Crear vector	<code>c(1, 2, 3)</code>
Ver clase	<code>class(x)</code>
Detectar NA	<code>is.na(x)</code>
Media sin NA	<code>mean(x, na.rm = TRUE)</code>
Crear data frame	<code>data.frame(...)</code>
Importar CSV	<code>read_csv("archivo.csv")</code>
Importar Excel	<code>read_excel("archivo.xlsx")</code>
Importar Stata	<code>read_dta("archivo.dta")</code>
Inspeccionar	<code>glimpse(base); summary(base)</code>
Seleccionar columnas	<code>select(base, x, y)</code>
Filtrar filas	<code>filter(base, x > 0)</code>
Crear variable	<code>mutate(base, z = x / y)</code>
Ordenar	<code>arrange(base, desc(x))</code>
Agrupar	<code>group_by(base, grupo)</code>
Resumir	<code>summarise(base, media = mean(x))</code>
Unir	<code>left_join(x, y, by = "id")</code>
Histograma	<code>ggplot(base, aes(x)) + geom_histogram()</code>
Dispersión	<code>ggplot(base, aes(x, y)) + geom_point()</code>
Correlación	<code>cor(x, y, use = "complete.obs")</code>
Rezago	<code>lag(x, 1)</code>
Regresión	<code>lm(y ~ x1 + x2, data = base)</code>
Resumen modelo	<code>summary(modelo)</code>
Coeficientes	<code>coef(modelo)</code>
Residuos	<code>residuals(modelo)</code>
Exportar CSV	<code>write_csv(base, "salida.csv")</code>

Errores frecuentes y cómo diagnosticarlos

Mensaje / síntoma	Causa probable	Qué revisar
object ... not found	nombre mal escrito o no creado	names(base), Environment, orden del script
could not find function	paquete no cargado o función mal escrita	library(paquete), ortografía
file does not exist	ruta o nombre de archivo incorrectos	getwd(), list.files(), extensión
NAs introduced by coercion	texto convertido a número sin ser numérico	valores originales y class()
resultado NA al calcular media	hay valores faltantes	is.na(), na.rm = TRUE
join produce muchas filas	llave no es única en una o ambas bases	count(llave) > filter(n > 1)
lag mezcla unidades	no se agrupó/ordenó correctamente	arrange(unidad, tiempo), group_by(unidad)
modelo usa menos observaciones	lm omitió filas con NA	nobs(modelo), colSums(is.na(base))

Banco adicional de práctica

54. Crea un vector de 12 salarios y calcula media, mediana, desviación estándar y cuartiles.
55. Simula una variable desempleado con TRUE/FALSE y cuenta cuántos TRUE existen.
56. Crea un data frame con 10 empresas: ventas, trabajadores, sector y región.
57. Filtra empresas con ventas mayores a un umbral y ordena de mayor a menor.
58. Convierte ventas a logaritmo después de verificar que no existan ceros ni negativos.
59. Cuenta cuántos NA existen en cada columna de una base.
60. Detecta identificadores duplicados y explica por qué no conviene eliminarlos sin revisar su significado.
61. Agrupa empleo por región y calcula ingreso promedio, mediana y n.
62. Agrupa por sexo y sector y calcula salario promedio.
63. Une una base de personas con otra base regional usando region.
64. Usa anti_join() para detectar regiones sin coincidencia.
65. Construye un histograma de ingreso y describe asimetría visual.
66. Construye un boxplot de ingreso por formalidad.
67. Construye un scatter de experiencia e ingreso.
68. Calcula correlación de educación e ingreso usando observaciones completas.
69. Crea una dummy urbano = 1 si area == "Urbana".
70. Crea un término edad2 y explica qué permite representar en un modelo.
71. En un panel región-año, crea el rezago de inversión dentro de cada región.
72. Estima lm(ingreso ~ educacion) e identifica Y, X, intercepto y pendiente.
73. Escribe un script completo que importe, limpie, transforme, describa y exporte una base sin pasos manuales.

Glosario mínimo

Término	Definición operativa
Objeto	Elemento guardado en memoria con un nombre.
Vector	Conjunto ordenado de valores del mismo tipo básico.

Término	Definición operativa
Data frame / tibble	Tabla rectangular de filas y columnas.
NA	Valor faltante.
Función	Instrucción que recibe argumentos y devuelve un resultado.
Paquete	Colección de funciones, datos y documentación.
Pipe >	Envía el resultado de un paso al siguiente.
Llave	Variable o combinación de variables usada para identificar o vincular registros.
Dummy	Variable binaria codificada usualmente 0/1.
Factor	Representación de una variable categórica.
Panel	Datos de múltiples unidades observadas en múltiples periodos.
Rezago	Valor previo de una variable dentro de una secuencia temporal.
Residuo	Diferencia entre valor observado y valor ajustado por un modelo.
Reproducibilidad	Capacidad de reconstruir resultados ejecutando el código sobre los mismos insumos.

Lista de comprobación final

- ☐ Puedo crear una carpeta raíz, abrir un RStudio Project y trabajar con rutas relativas.
- ☐ Puedo distinguir R Script (.R), R Markdown (.Rmd) y Markdown (.md), y elegir cuándo usar cada uno.
- ☐ Puedo detectar y tratar NA de manera explícita.
- ☐ Puedo instalar paquetes por código o manualmente, cargarlos con library() e importar CSV, Excel y DTA.
- ☐ Puedo inspeccionar una base antes de analizarla.
- ☐ Puedo usar select(), filter(), arrange(), mutate(), distinct(), group_by() y summarise().
- ☐ Puedo verificar una llave antes de hacer un join.
- ☐ Puedo construir histogramas, boxplots y gráficos de dispersión.
- ☐ Puedo crear logaritmos, dummies, cuadrados, rezagos y diferencias.
- ☐ Puedo reconocer la estructura región-año de un panel.
- ☐ Puedo estimar un lm() básico y extraer coeficientes, ajustados y residuos.
- ☐ Puedo diferenciar asociación estadística de causalidad.
- ☐ Puedo exportar una base y volver a reproducir el proceso desde el script.

Referencias y recursos de consulta

Morales Alberto, A. A. (2023). Introducción a R con RStudio: ¿Qué es R y RStudio?, primeros pasos e importación de datos. Material práctico.

R Core Team. R Manuals y documentación del paquete stats (función lm y herramientas estadísticas base).

Posit. RStudio IDE User Guide: proyectos, scripts y organización del trabajo.

Wickham, H. y colaboradores. dplyr: manipulación de datos con filter(), select(), mutate(), group_by(), summarise() y joins.

Wickham, H. y colaboradores. ggplot2: gramática de gráficos para exploración y comunicación de datos.

Tidyverse. readr y haven: importación de archivos de texto, Stata y SPSS.

Siguiente paso

Con estas bases técnicas ya puedes avanzar a un curso formal de Econometría Aplicada con R: MCO, inferencia, supuestos, errores robustos, variables cualitativas, especificación, panel y series de tiempo.